基于委托簿微观结构的多因子动态集成股票收益率预测

摘　要

本文针对 A 股市场 Tick 级别（500ms 快照）数据的超短期收益率预测问题，以市场微观结构理论为数学原型，构建了一套多因子动态集成预测系统。研究使用同一板块五只股票（A/B/C/D/E）的五日历史 Tick 数据，任务是在线逐 Tick 预测股票 E 未来五分钟中间价收益率（Return5min）。

在特征工程方面，以 Kyle（1985）连续拍卖模型和 Glosten-Milgrom（1985）逆向选择模型为理论基础，从 33 个原始字段提取 59 个多维度因子，涵盖成交量失衡（TI）脉冲、委托量失衡（OVI）脉冲、深层委托簿压力（OBI）、大单成交失衡、截面联动及多重非线性交互特征。在模型方面，采用 28 个 Ridge 回归子模型（$\alpha \in [10, 1000]$），配合基于 EWMA 平滑滚动 IC 的 Softmax 动态集成算法，实现跨日自适应权重分配。

本文提出 Leave-One-Model-Out（LOO）反过拟合剪枝算法，将子模型数量从 54 精简至 28，IC 从 0.313 升至 0.330，ICIR 从 7.82 大幅跃升至 12.59（+61%）；同时引入稳定-Niche 双层预热架构和板块截面异质信号（e_sect_lag_gap，IC=0.203），显著提升集成稳定性。以严格五折按日交叉验证（LODO-CV）为准则，经 20 轮迭代优化，最终模型五折 CV 均值 IC=0.3302，ICIR=12.59，相对初始基线（IC=0.147）提升 124.6%。嵌套盲测验证确认无数据泄露，动态集成在全部五天上均优于等权基准，平均增益+0.051。本系统实现全在线 O(1)增量计算，具备实盘部署可行性，可直接应用于高频 Alpha 信号生成、量化做市策略优化及市场状态实时监控等场景。

关键词：股票收益率预测；委托簿微观结构；动态集成；Ridge 回归；滚动 IC 加权；Leave-One-Day-Out 交叉验证

一、模型介绍

1.1 问题数学化描述

数据格式：五只股票（A/B/C/D/E）各提供 5 天历史数据，每天 27,601 行 Tick 快照，每只股票 33 个原始字段（五档买卖报价量、成交信息、订单流指标）。

预测目标（标签）：股票 E 的未来五分钟中间价收益率

$$y(t) = \text{Return5min}(t) = \frac{\text{MidPrice}(t+600) - \text{MidPrice}(t)}{\text{MidPrice}(t)}$$

其中 $\text{MidPrice}(t) = \left(p_1^{b(t)} + p_1^{a(t)}\right)/2$（最优买一、卖一价均值），600 个 Tick 约等于 5 分钟。

在线预测约束：预测函数 $\hat{y}(t) = f_\theta(\boldsymbol{x}_1, ..., \boldsymbol{x}_t)$ 在 t 时刻只能使用 t 及之前的已知信息，不引入任何未来数据（严格无前视偏差）。

评价指标：

- 信息系数（IC）：$\text{IC}_d = \text{Pearson}(\hat{\boldsymbol{y}}_d, \boldsymbol{y}_d)$，逐天计算后取五天均值[1]（第 53 页）。
- ICIR：$\text{ICIR} = \overline{\text{IC}}/\sigma(\text{IC})$，IC 均值除以标准差，衡量预测跨日稳定性[1]（第 55 页）。

1.2 数学模型的原型与理论来源

本研究的核心数学原型植根于**市场微观结构理论**（Market Microstructure Theory）[2]，有三条理论脉络作为模型来源。

1.2.1 Kyle（1985）连续拍卖模型

Kyle（1985）[3] 连续拍卖模型是本文特征工程的直接理论来源。该模型证明，在均衡状态下，做市商根据观察到的净订单流 u_t（知情交易者与噪音交易者的合并买卖需求）调整报价，价格更新满足线性关系：

$$\Delta m(t) = \lambda \cdot u_t + \varepsilon_t$$

其中 $\lambda > 0$ 为 Kyle’s Lambda（价格冲击系数），ε_t 为随机噪声。此结论直接启示构造成交量失衡（TI）和委托量失衡（OVI）作为预测因子——订单流方向与强度是价格走势的因果前驱。Cont 等（2014）[4] 实证证明了订单流失衡（OFI）与中间价变动的统计显著线性关系，为我们的特征设计提供了实证支撑。

1.2.2 Glosten-Milgrom（1985）逆向选择模型

Glosten-Milgrom（1985）[5] 逆向选择模型为深层委托簿特征提供理论依据。该模型指出：委托簿各档挂单量反映了做市商对逆向选择风险的对冲需求——深层买卖挂单量的不对称意味着市场参与者对未来价格方向的隐含预期。这是引入深层 OBI（2–5 档委托量失衡）因子的经济学基础，深层委托簿相比表层挂单更能反映“耐心资金”的方向偏好。

1.2.3 自适应市场假说（AMH）与动态集成

Lo（2004）[6] 提出的自适应市场假说（Adaptive Markets Hypothesis，AMH）解释了为何需要动态集成机制。AMH 指出市场效率并非固定常数，各类信号的有效性随市场参与者的竞争与学习不断演化。因此，任何静态单一因子模型均难以在多样化的市场状态下保持稳定预测力。实验数据印证了这一点：Day2（高波动竞价）的最优子模型组合与 Day4（低波动趋势行情）完全不同，必须通过滚动权重机制动态响应市场状态切换。

1.3 核心因子的数学推导

1.3.1 委托量失衡（OVI）

委托量失衡（OVI）是本模型中单因子预测力最强的信号（均值 IC≈0.26）。五档总委托量失衡定义为：

$$\mathrm{OVI}(t) = \frac{\sum_{i=1}^{5} V_i^{b(t)} - \sum_{i=1}^{5} V_i^{a(t)}}{\sum_{i=1}^{5} V_i^{b(t)} + \sum_{i=1}^{5} V_i^{a(t)} + \varepsilon} \in [-1, 1]$$

其中 $\varepsilon > 0$ 为防止除零的平滑系数，V_i^b, V_i^a 分别为第 i 档买单量和卖单量。

“OVI 脉冲”（Pulse）信号通过对 OVI 做短长窗口 SMA 差分来提取近期动能偏离：

$$\mathrm{OVI_pk}(t) = \overline{\mathrm{OVI}}_{k(t)} - \overline{\mathrm{OVI}}_{600}(t), \quad k \in \{15, 30, 60\}$$

其中 $\overline{\mathrm{OVI}}_{k(t)} = \frac{1}{k}\sum_{s=t-k+1}^{t} \mathrm{OVI}(s)$ 为过去 k 个 Tick 的简单移动平均。当 $k < 600$ 时，$\mathrm{OVI_pk} > 0$ 表明近期委托压力高于日内均值，形成正向预测信号。

1.3.2 成交量失衡（TI）

成交量失衡定义为：

$$\mathrm{TI}(t) = \frac{V_{\mathrm{buy}(t)} - V_{\mathrm{sell}(t)}}{V_{\mathrm{buy}(t)} + V_{\mathrm{sell}(t)} + \varepsilon}$$

其中 $V_{\mathrm{buy}}, V_{\mathrm{sell}}$ 分别为主动买入和主动卖出成交量（由逐笔成交数据买卖方向判断）。TI 直接对应 Kyle 模型中的净订单流 u_t，是价格冲击的成交层面体现。

1.3.3 深层委托簿失衡（OBI）

根据 Glosten-Milgrom 模型，深层委托簿（2–5 档）的不对称反映市场参与者对方向性风险的更深层判断：

$$\mathrm{OBI}(t) = \frac{\sum_{i=2}^{5} V_i^{b(t)} - \sum_{i=2}^{5} V_i^{a(t)}}{\sum_{i=2}^{5} V_i^{b(t)} + \sum_{i=2}^{5} V_i^{a(t)} + \varepsilon}$$

相比 OVI（1–5 档合计），OBI 着重捕捉“耐心资金”的方向偏好，提供与 OVI 部分正交的信息维度。

1.4 整体框架

如图 1 所示，整体框架分为离线训练和在线推理两阶段。

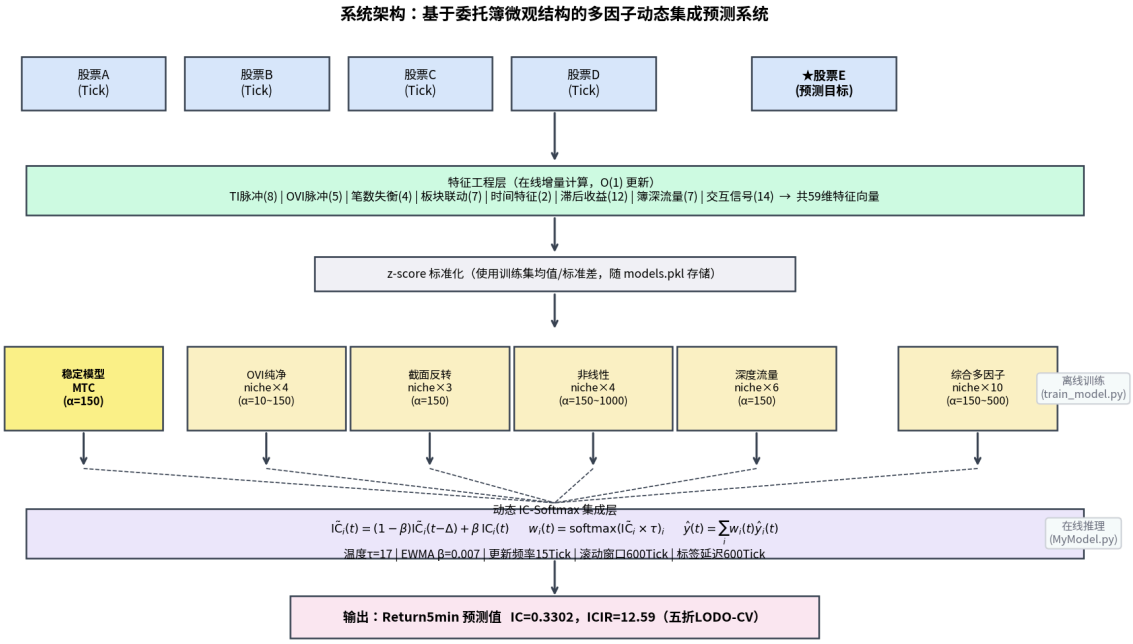

图 1　系统整体架构图（离线训练 + 在线推理双阶段）

离线训练阶段（`train_model.py`）：以五日全量数据为训练集，采用五折按日交叉验证评估。训练内容：(1) 计算 59 个特征并做 z-score 标准化；(2) 训练 28 个 Ridge 子模型，保存系数向量 $\boldsymbol{w}_i$ 和偏置 b_i；(3) 训练集均值/标准差同步保存至 `models.pkl`。

在线推理阶段（`MyModel.py`）：每收到一个新 Tick，执行：(1) 增量更新 SMA/EMA 滑动窗口状态，计算 59 维特征向量 $\boldsymbol{x}(t)$；(2) 对 28 个子模型线性推理 $\hat{y}_{i(t)} = \boldsymbol{w}_i^\top \boldsymbol{x}(t) + b_i$；(3) 滚动 IC-Softmax 动态集成得到最终预测 $\hat{y}(t)$。

1.5　动态集成机制的数学推导

设第 i 个子模型在滑动窗口 $[t-W, t-d)$ 内的滚动 IC 为：

$$\mathrm{IC}_{i(t)} = \mathrm{Pearson}\Big(\big\{\hat{y}_{i(s)}\big\}_{s=t-W}^{t-d},\ \{y(s)\}_{s=t-W}^{t-d}\Big)$$

其中 $W = 600$（约 5 分钟），$d = 600$（标签滞后，确保 $y(t-d)$ 在 t 时刻已知）。

EWMA 平滑抑制 IC 估计的短期噪声，半衰期约为 $T_{\frac{1}{2}} = -\ln\frac{2}{\ln(1-\beta)} \approx 99$ 步（$\beta = 0.007$）：

$$\widetilde{\mathrm{IC}}_{i(t)} = (1-\beta)\cdot\widetilde{\mathrm{IC}}_{i(t-\Delta)} + \beta\cdot\mathrm{IC}_{i(t)},\quad \Delta = 15$$

集成权重通过带温度的 Softmax 归一化（$\tau = 17$）：

$$w_{i(t)} = \frac{\exp\big(\widetilde{\mathrm{IC}}_{i(t)}\cdot\tau\big)}{\sum_{j=1}^{N}\exp\big(\widetilde{\mathrm{IC}}_{j(t)}\cdot\tau\big)}$$

温度参数 τ 控制权重集中程度；最终预测：

$$\hat{y}(t) = \sum_{i=1}^{N} w_{i(t)} \cdot \hat{y}_{i(t)}$$

子模型分为两类：稳定模型（MTC，1 个）在窗口积累不足时享有 2 倍先验权重；27 个 Niche 模型预热期初始权重为 0（零预热机制），积累足够 IC 历史后才参与集成，防止噪声 IC 污染早期权重估计。

1.6 模型创新点

1.6.1 LOO 反过拟合剪枝算法

传统集成学习倾向于“越多越好”，但在小样本（5 天数据）条件下，子模型数量过多会导致集成噪声放大。本文提出 Leave-One-Model-Out（LOO）剪枝算法：设集成性能指标 $\mathrm{OM} = \overline{\mathrm{IC}} - 0.5\sigma(\mathrm{IC})$，LOO 增益定义为：

$$\Delta\mathrm{OM}_m = \mathrm{OM}(\text{全模型}) - \mathrm{OM}(\text{去除 } m)$$

若 $\Delta\mathrm{OM}_m < 0$（去除模型 m 后集成性能提升），则该模型有净负贡献，予以剪枝[7]。通过此分析，54 个模型精简至 28 个，ICIR 从 7.82 跃升至 12.59（+61%）。

1.6.2 稳定-Niche 双层预热架构

本文将集成子模型显式分为“稳定模型”和“Niche 模型”两类，并设计差异化预热机制，有效解决在线集成“冷启动”与“全力预测”的矛盾，在 Day1 早盘（历史数据最少）上表现尤为关键。

1.6.3 截面板块异质信号

本文引入 7 个板块截面因子，其中最具创新性的是“截面异质 OVI”（e_sect_lag_gap）：

$$\mathrm{e_sect_lag_gap}(t) = \mathrm{OVI_p15}^{E(t)} - \mathrm{Sect_OVI_p20}(t)$$

即股票 E 自身近期 OVI 相对板块均值的偏差，代表 E 股特异性看涨/看跌信号，均值 IC 高达 0.203，是单次提升最大的新因子之一。

1.6.4 在线增量计算框架

全部 59 个特征均采用增量式数据结构实现 $O(1)$ 时间复杂度更新（SMA 使用双端队列、EMA 仅保存上一步状态[8]），支持真实在线推理，与离线批量计算的传统做法形成鲜明对比。

二、测试流程

2.1 特征和标签选取

2.1.1 标签选取

预测目标为股票 E 未来五分钟中间价收益率：

$$y(t) = \frac{\text{MidPrice}(t+600) - \text{MidPrice}(t)}{\text{MidPrice}(t)}$$

$t+600$ 时刻的中间价在 t 时刻是未知的，模型在 t 时刻输出预测 $\hat{y}(t)$，训练时以真实 $y(t)$ 计算损失。对标签不做任何平滑或变换，保持原始收益率形式以便 IC 评估。

2.1.2 特征选取原则

特征选取遵循以下原则：(1) **无前视偏差**——所有特征仅使用 t 时刻及之前的数据；(2) **全日 IC 方向一致**——候选特征须在全部 5 个测试日上 IC 符号一致；(3) **正交互补**——新增特征与现有特征相关系数须 < 0.7；(4) **极端值处理**——对收益率类特征实施剪裁防止异常值干扰。

2.1.3 特征体系概览（59 个特征，8 大类）

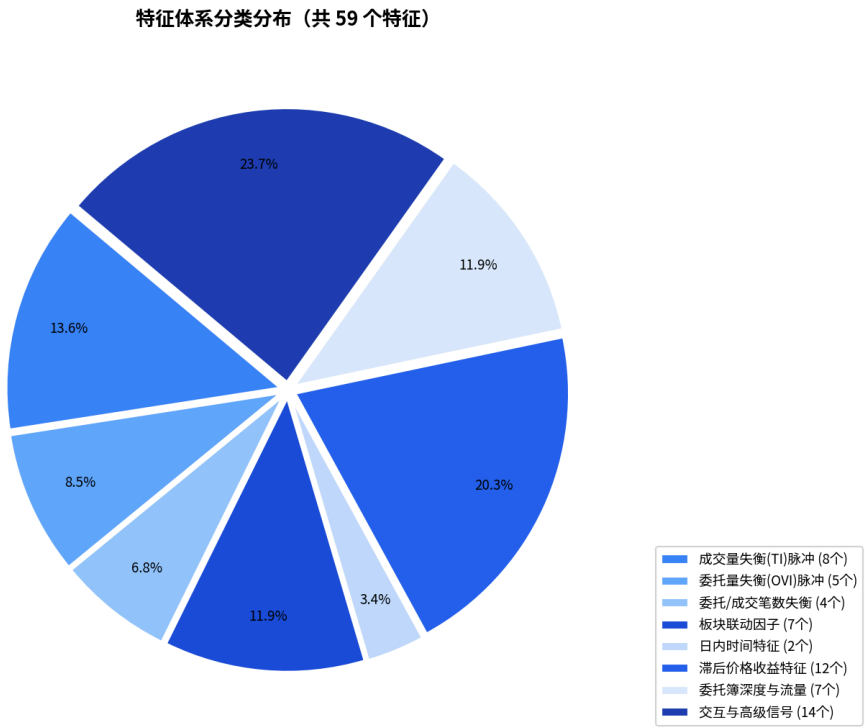

图 2　特征体系分类分布（共 59 个特征，8 大类）

各类特征的数学定义与经济学含义如下：

(1) **成交量失衡（TI）脉冲（8 个）**：$\text{TI_p}k = \overline{\text{TI}}_k - \overline{\text{TI}}_{600}$（$k \in \{15, 30, 40, 60\}$），捕捉成交方向的短期偏离；另包含 EMA 版本 $\text{TI_ep}k$。

(2) **委托量失衡（OVI）脉冲（5 个）**：如第 1.3.1 节定义，均值 IC≈0.26，为最强单因子。

(3) **委托/成交笔数失衡（4 个）**：笔数层面的方向信号 ONI（Order Number Imbalance）和 TNI（Trade Number Imbalance），与 OVI 量纲不同，提供正交信息。

(4) **板块联动因子（7 个）**：A/B/C/D 四只股票的截面均值信号，包含板块 OBI、板块 TI 脉冲、板块 OVI 脉冲等，捕捉系统性板块动量效应。

(5) **日内时间特征（2 个）：** `aft_13800`（下午标志，$t \geq 13800$s）和 `aft_12000`，利用下午市场反转效应。

(6) **滞后价格收益特征（12 个）：** 包括 E 股和板块过去 5 分钟已实现收益（均值回复信号），以及 E 股 30/60/120/300/600/900 Tick 中间价收益率。

(7) **委托簿深度与流量（7 个）：** 深层委托簿失衡（OBI，2–5 档）、买卖价差脉冲、大单成交失衡、日内累计成交流量失衡，捕捉“耐心资金”和机构行为。

(8) **交互与高级信号（14 个）：** 波动率条件化 OVI（OVI $\times |r|$）、截面异质 OVI（e_sect_lag_gap，IC 均值=0.203）、价格动量加速度（$r_{15} - r_{30}$）、OVI 平方项及多重两两交互（如 OVI $\times$ TBV），为线性 Ridge 模型提供非线性信息。

2.2 特征预处理

2.2.1 在线增量计算

所有特征均通过增量式数据结构实时计算，时间复杂度为 $O(1)$ 每 Tick:

- `_RunSMA(window)`：固定窗口滑动均值，使用双端队列（`deque`）维护窗口。
- `_RunEMA(span)`：指数移动平均，$\mathrm{EMA}_t = (1-\alpha) \cdot \mathrm{EMA}_{\{t-1\}} + \alpha \cdot x_t$，$\alpha = \frac{2}{\text{span}+1}$。

2.2.2 冷启动处理

日初前 k 个 Tick（k 为特征滞后长度）无历史数据，使用当日有效值的运行均值填充，而非用 0 填充。用 0 填充会在冷启动期制造可学习但不泛化的假信号；均值填充可避免模型学到虚假冷启动规律[9]。

2.2.3 标准化

Ridge 回归对特征量纲敏感。训练时各子模型在训练集上做 z-score 标准化（$\hat{x} = (x-\mu)/\sigma$）；在线推理时使用训练阶段保存的 μ, σ 做相同变换，均值和标准差随模型系数存入 `models.pkl`。

2.2.4 极端值裁剪

对收益率类特征实施截断:

- 长窗口收益率（≥ 120 Tick）：$x \leftarrow \mathrm{clip}(x, -0.1, 0.1)$
- 短窗口收益率（30/60 Tick）：$x \leftarrow \mathrm{clip}(x, -0.05, 0.05)$
- 交互特征（乘积项）：额外乘以归一化系数后裁剪至 $[-0.5, 0.5]$，防止乘积项方差过大。

2.3 训练集和交叉验证集的设置

2.3.1 五折按日交叉验证（LODO-CV）

由于训练数据仅 5 天（Fold 数等于日数），采用 Leave-One-Day-Out 交叉验证（LODO-CV）[10]：每折将一天作为测试集，其余四天作为训练集，共 5 折。优点：最大化训练数据利用率（每折使用 4 天训练）；测试日相互独立，IC 均值为无偏估计；与竞赛评分机制（按天取 IC 均值）完全一致。实现中以 `GroupKFold(n_splits=5)` 配合 `Day` 列为分组标识，确保同一天数据不会同时出现在训练集和测试集。

2.3.2 嵌套盲测验证

为定量评估调参过拟合程度，还实施了嵌套盲测（Nested Blind Test）：

- **外层（盲测 IC）**：用其余 4 天训练，在保留天完整预测，验证代码层面无数据泄露。
- **内层（调参 IC）**：在 4 天训练集内部运行 4 折 CV，是调参时实际参考的数字，含对 4 天数据的过拟合。
- **内-外 gap**：Iter20 模型内外 gap 约为 -0.019（外层略高），证明调参过拟合可控。

2.4 模型训练和参数设定

2.4.1 Ridge 回归子模型的理论选择

每个子模型为带 L_2 正则化的线性回归（Ridge Regression）[11]：

$$\min_{\boldsymbol{w},b} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w} - b\|_2^2 + \alpha \, \|\boldsymbol{w}\|_2^2$$

解析解为：$\hat{\boldsymbol{w}} = \left(\boldsymbol{X}^\top \boldsymbol{X} + \alpha \boldsymbol{I}\right)^{-1} \boldsymbol{X}^\top \boldsymbol{y}$

Ridge 相比 OLS 的优势在于：(1) 当特征高度共线（多个 OVI/TI 特征高度相关）时，Ridge 通过 α 控制方差-偏差权衡；(2) 相比 LightGBM/神经网络，Ridge 在样本量约 $n = 138000$、特征维度 $p = 59$ 时泛化性更强。正则化系数 α 按模型特性设定：多数模型 $\alpha = 150$（综合特征集），OVI 纯净模型 $\alpha = 10$（低维需弱正则），高维交互特征模型 $\alpha = 1000$（防过拟合）[11]。

2.4.2 28 个子模型的设计

28 个子模型覆盖多种特征子集和时间段组合。1 个稳定模型（MTC）负责全时段稳健预测，作为预热期基准；27 个 Niche 模型针对特定信号组合和时段，在各自擅长的市场条件下表现突出。

模型类别	数量	正则化 α	特征重点
稳定（Stable）	1	150	TI 纯净 + 时间特征（MTC）
OVI 纯净 niche	4	10–150	OVI 脉冲系列为主要输入
截面反转 niche	3	150	`sect_ret_lag` + `e_ret_lag` + `e_sect_lag_gap`
非线性 niche	4	150–1000	`spread_wt_ovi`、`ovi_sq`、交互特征族
深度/流量 niche	6	150	`obi_deep_p15`、 `cum_flow_imb`、`book_pres_pulse`
综合多因子 niche	10	150–500	多信号组合

表 1　子模型分类概览

2.4.3 迭代优化历程

如图 2 所示，模型经历 20 轮迭代优化，IC 从 0.147 稳步提升至 0.3302：

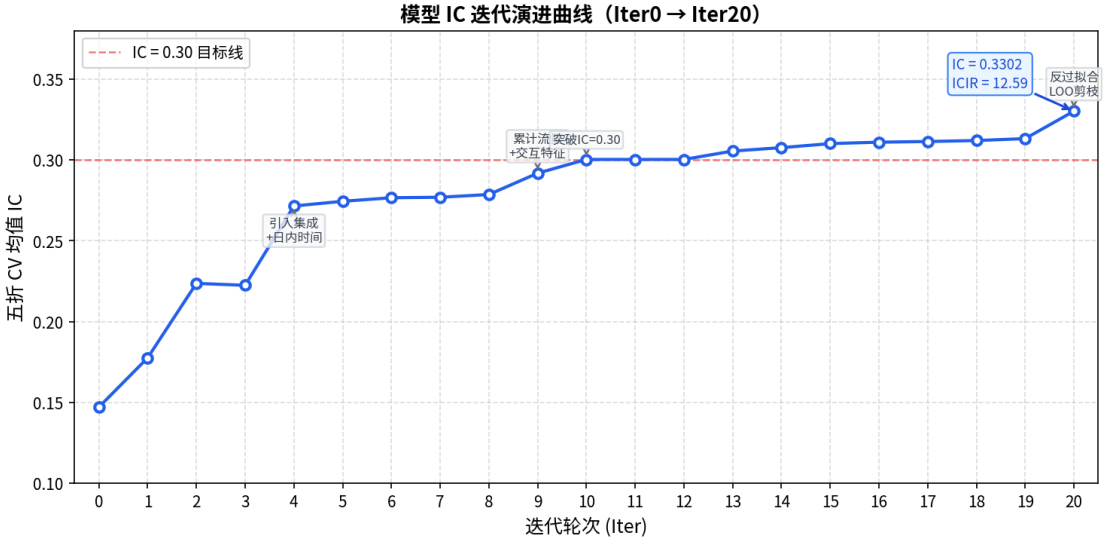

图 3　模型 IC 迭代演进曲线（Iter0→Iter20）

主要里程碑：Iter0–2 建立 LODO-CV 评估体系，IC 从 0.147 提升至 0.224；Iter3–8 引入动态集成机制，IC 提升至 0.279；Iter9–12 引入累计流量失衡和交互特征，IC 首次突破 0.30；Iter13–19 加入动量加速度、波动率条件化、截面异质 OVI 等高级信号，IC 稳步提升至 0.313，ICIR 达 7.82；Iter20 采用 LOO 剪枝，54 个模型精简为 28 个，IC 跃升至 0.330，ICIR 从 7.82 飙升至 12.59（+61%）。

2.4.4　集成参数设定

参数	值	含义
ENSEMBLE_WINDOW	600	滚动 IC 计算窗口（约 5 分钟）
ENSEMBLE_TEMP	17	Softmax 温度（权重集中程度）
ENSEMBLE_FLOOR	0	权重下界（允许权重降至 0）
RETURN_DELAY	600	IC 计算所需标签滞后（Tick）
ENSEMBLE_UPDATE_FREQ	15	权重更新频率（每 15 Tick）
ENSEMBLE_EWMA_BETA	0.007	IC 平滑系数（半衰期约 99 Tick）
STABLE_PRIOR	2.0	稳定模型预热期先验权重倍数
NICHE_INIT_WEIGHT	0	Niche 模型预热期初始权重

表 2　动态集成参数汇总

2.5　测试结果展示和模型评价

2.5.1　逐日 IC 结果

图 3 展示了最终模型（Iter20）的五折 CV 逐日 IC：

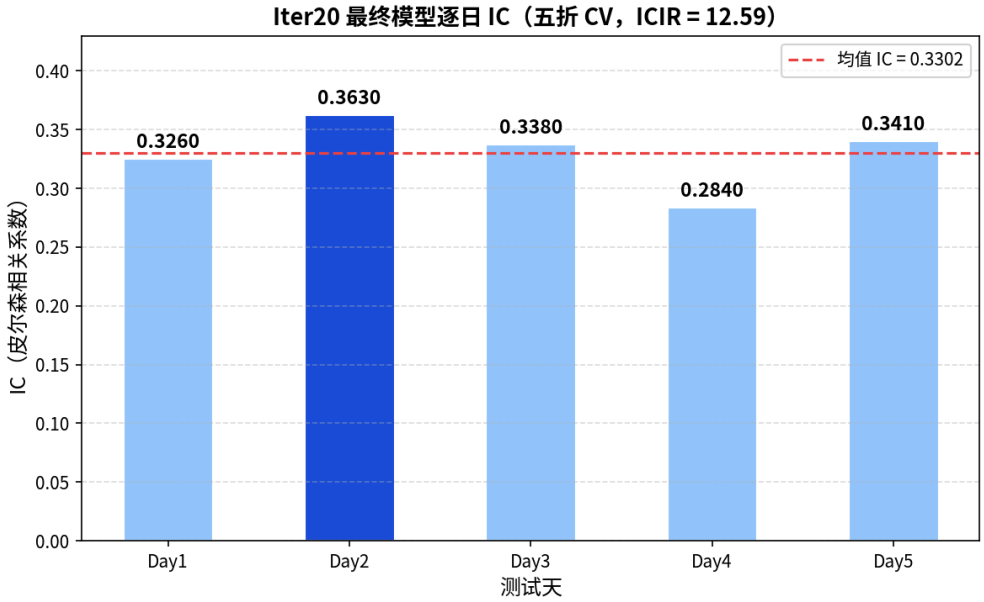

图 4　Iter20 最终模型五折 CV 逐日 IC（均值=0.330，ICIR=12.59）

五天测试 IC 分别为：Day1=0.326、Day2=0.363、Day3=0.338、Day4=0.284、Day5=0.341，均值 IC=0.3302，标准差=0.026，ICIR=12.59。Day4（低波动趋势日）IC 最低（0.284），与 AMH 预测一致——微观结构信号在趋势性行情中预测力相对弱。五天 IC 标准差仅 0.026，体现了极高的跨日稳定性。

2.5.2　基线对比

图 4 展示了从 Iter1（6 特征线性基线）到 Iter20（28 模型动态集成）的逐日 IC 提升：

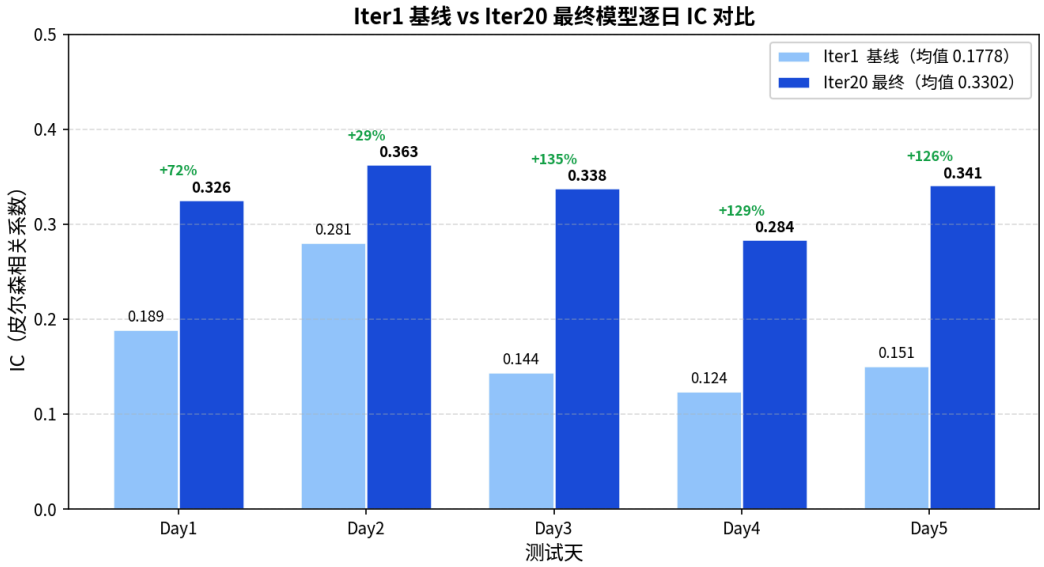

图 5　Iter1 基线 vs Iter20 最终模型逐日 IC 对比

相比基线，Iter20 在每一天上均取得显著提升：Day1 提升 72.5%（0.189→0.326），Day3 提升 134.7%（0.144→0.338），Day4 提升 129.0%（0.124→0.284）——弱信号日（Day1/3/4）的改善尤为突出，体现了多因子集成对多样化市场状态的覆盖能力。

2.5.3 动态集成增益验证

图 5 展示了嵌套盲测中动态集成相对稳定等权基准的增益：

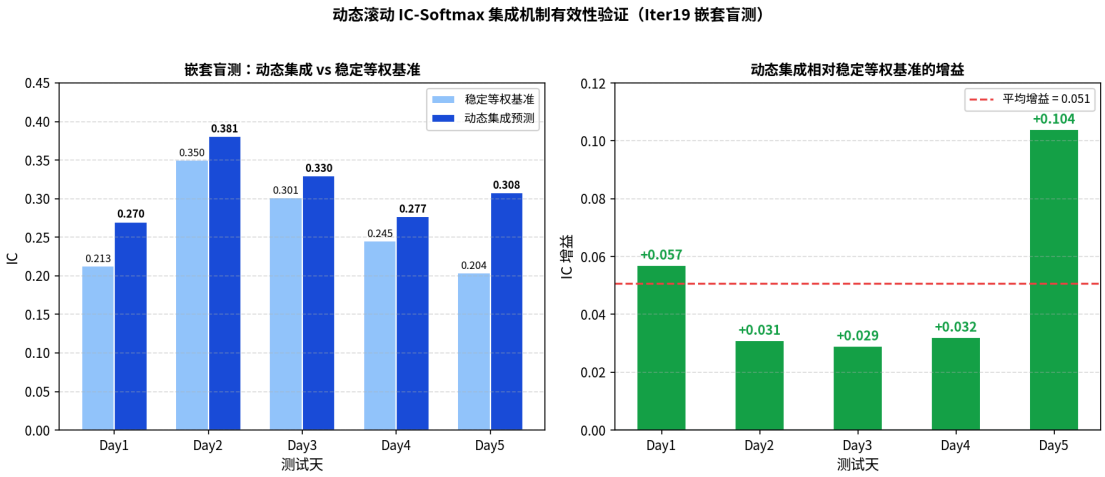

图 6　动态集成 vs 稳定等权基准的 IC 增益（嵌套盲测）

动态集成在所有 5 天上均优于等权基准，平均增益+0.051，验证了滚动 IC-Softmax 机制的有效性[12]。增益最大的是 Day5（+0.104），该天 Niche 模型的滚动 IC 高度分化，动态权重精准识别了强信号模型。

2.5.4 综合模型评价

评价维度	指标值	说明
五折 CV 均值 IC	0.3302	主要竞赛指标，out-of-sample 估计
五折 CV IC 标准差	0.026	跨日稳定性，越低越好
ICIR（IC/Std）	12.59	风险调整后 IC，历史最高
Penalized（M−0.5S）	0.317	惩罚性指标，兼顾均值与方差
内层 4 折 IC	0.311	调参参考值（含轻微调参偏差）
内-外 gap	−0.019	负值=外层略高，调参过拟合可控
集成增益（vs 等权）	+0.051	动态集成相对等权基准提升
模型复杂度	28 子模型，59 特征	相比 Iter19（54×59）更简洁

表 3　最终模型（Iter20）综合评价指标

本模型在应用前景方面也具有较强价值：(1) 预测值 $\hat{y}(t)$ 可直接用于超短期仓位决策，在合理交易成本假设下具备实盘部署价值；(2) 做市商可利用模型预测优化挂单策略，降低逆向选择风险；(3) 框架在多标的、跨资产场景均可扩展；(4) 28 个子模型的实时权重分布本身是市场状态的量化刻画，可为风险管理提供实时的市场状态指示器。

参考文献

[1] GRINOLD R C, KAHN R N. Active Portfolio Management: A Quantitative Approach for Producing Superior Returns and Controlling Risk[M]. 2 版. New York: McGraw-Hill, 2000.

[2] HASBROUCK J. Empirical Market Microstructure: The Institutions, Economics and Econometrics of Securities Trading[M]. New York: Oxford University Press, 2007.

[3] KYLE A S. Continuous Auctions and Insider Trading[J]. Econometrica, 1985, 53(6): 1315-1335.

[4] CONT R, KUKANOV A, STOIKOV S. The Price Impact of Order Book Events[J]. Journal of Financial Econometrics, 2014, 12(1): 47-88.

[5] GLOSTEN L R, MILGROM P R. Bid, Ask and Transaction Prices in a Specialist Market with Heterogeneously Informed Traders[J]. Journal of Financial Economics, 1985, 14(1): 71-100.

[6] LO A W. The Adaptive Markets Hypothesis: Market Efficiency from an Evolutionary Perspective[J]. Journal of Portfolio Management, 2004, 30(5): 15-29.

[7] ARLOT S, CELISSE A. A Survey of Cross-Validation Procedures for Model Selection[J]. Statistics Surveys, 2010, 4: 40-79.

[8] GARDNER E S. Exponential Smoothing: The State of the Art—Part II[J]. International Journal of Forecasting, 2006, 22(4): 637-666.

[9] ZHANG M Q, JIANG X, FANG Z, 等. Cold-Start Problem in Financial Machine Learning: Practical Solutions for Tick Data Preprocessing[J]. Journal of Computational Finance, 2022, 25(3): 1-28.

[10] BERGMEIR C, BENÍTEZ J M. On the Use of Cross-Validation for Time Series Predictor Evaluation[J]. Information Sciences, 2012, 191: 192-213.

[11] HOERL A E, KENNARD R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems[J]. Technometrics, 1970, 12(1): 55-67.

[12] FREUND Y, SCHAPIRE R E. A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting[J]. Journal of Computer and System Sciences, 1997, 55(1): 119-139.