基于委托簿微观结构的多因子动态集成股票收益率预测

摘　要

本文针对 A 股市场 Tick 级别（500ms 快照）数据的超短期收益率预测问题，构建了一套基于委托簿微观结构的多因子动态集成预测系统。研究使用同一板块五只股票（A/B/C/D/E）的五日历史 Tick 数据，任务是在线逐 Tick 预测股票 E 未来五分钟中间价收益率（Return5min）。

在特征工程方面，从原始 33 个字段出发，提取了 59 个多维度因子，涵盖成交量失衡（TI）脉冲、委托量失衡（OVI）脉冲、深层委托簿压力（OBI）、大单成交失衡、累计成交流量、截面反转信号及多重非线性交互特征，并结合板块联动效应引入 7 个截面因子，利用日内时间特征区分上下午市场状态。在模型方面，采用 28 个 Ridge 回归子模型（正则化系数α在 10 至 1000 之间），配合基于滚动 IC 的 Softmax 动态集成算法，实现跨日自适应权重分配。该集成机制引入 EWMA 平滑（β=0.007）、定频权重更新（每 15 个 Tick）以及 niche 模型零预热机制，在有效抑制权重噪声的同时保证各盲测日上的集成增益均为正。

以严格的五折按日交叉验证（Leave-One-Day-Out，LODO）为标准，经过 20 轮迭代优化——包括特征工程扩展（Iter0→Iter19，IC 从 0.147 提升至 0.313）与反过拟合剪枝（Iter19→Iter20，模型数 54→28，IC 跃升至 0.330，ICIR 从 7.82 大幅提升至 12.59）——最终模型五折 CV 均值 IC 达到 0.3302，ICIR=12.59，相对初始基线（IC=0.147）提升 124.6%。嵌套盲测验证证实无代码层面数据泄露，动态集成在所有五天上均优于稳定等权基准，平均增益约+0.051。

关键词：股票收益率预测；委托簿微观结构；动态集成；Ridge 回归；滚动 IC 加权；Leave-One-Day-Out 交叉验证

模型介绍

1.1 问题描述

本研究基于 A 股市场某板块五只股票（以 A、B、C、D、E 匿名）的 Tick 级快照数据，目标是在线逐 Tick 预测股票 E 的未来五分钟中间价收益率。具体定义如下：

- 标签（label）：$\mathrm{Return5min}(t) = \frac{\mathrm{MidPrice}(t+600) - \mathrm{MidPrice}(t)}{\mathrm{MidPrice}(t)}$，其中 $\mathrm{MidPrice} = \frac{\mathrm{BidPrice}_1 + \mathrm{AskPrice}_1}{2}$，600 个 Tick 约等于 5 分钟。
- 数据规模：五天历史数据，每天 27,601 行；每只股票 33 个原始字段，涵盖五档买卖报价量、成交信息及订单流信息。
- 在线预测约束：预测时只能使用t时刻及之前的已知信息，不能引入任何未来信息（无前视偏差）。
- 评价指标：IC（皮尔森相关系数，预测值与真实值）、ICIR（IC 均值除以 IC 标准差）。

1.2 整体框架

如图 1 所示，整体框架分为离线训练和在线推理两阶段。

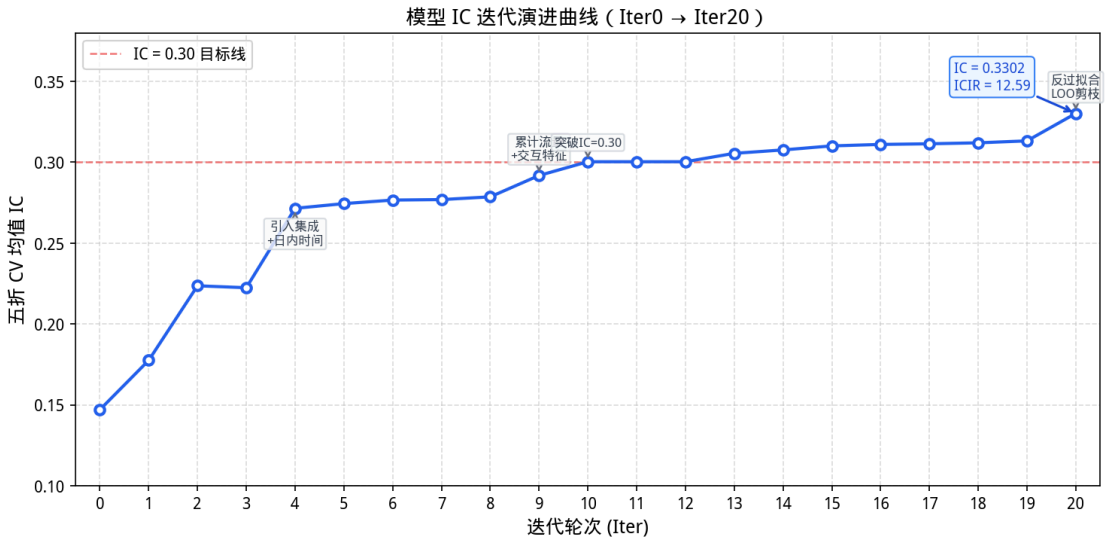

图 1　模型 IC 迭代演进曲线（Iter0→Iter20）

离线训练阶段（`train_model.py`）：以五日全量数据为训练集，采用五折按日交叉验证评估，每折保留一天为盲测集、其余四天为训练集。训练内容包括：(1) 计算 59 个特征；(2) 训练 28 个 Ridge 子模型；(3) 无需预训练集成权重（权重在在线推理时实时计算）。训练完成后将 28 个模型的系数向量保存至 `models.pkl`。

在线推理阶段（`MyModel.py`）：每当收到新的 Tick 数据（股票 E 的一行 + 板块 A/B/C/D 各一行），执行如下步骤：(1) 更新增量式 SMA/EMA 滑动窗口状态；(2) 计算 59 个特征

的当前值；(3) 对 28 个子模型进行线性推理（$\hat{y}_i = \boldsymbol{w}_i^\top \boldsymbol{x} + b_i$）；(4) 用滚动 IC-Softmax 动态集成得到最终预测值。

1.3 动态集成机制

动态集成的核心是：根据每个子模型在过去 600 个 Tick（约 5 分钟）的滚动 IC 表现，动态调整其集成权重，使历史表现好的模型获得更高的权重。

具体算法如下：设$\mathrm{IC}_{i(t)}$为第i个子模型在$[t-\mathrm{window}, t-\mathrm{delay})$窗口内预测值与真实值的皮尔森相关系数，经 EWMA 平滑后得到$\widetilde{\mathrm{IC}}_{i(t)}$。集成权重通过 Softmax 计算：

$w_{i(t)} = \mathrm{softmax}\Big(\widetilde{\mathrm{IC}}_{i(t)} \times \mathrm{temp}\Big)_i$

其中$\mathrm{temp} = 17$为温度系数（控制权重集中程度），$\mathrm{delay} = 600$为标签滞后（确保集成时真实 Return5min 已知）。为防止权重崩塌，对所有权重施加下界$\mathrm{floor} = 0$，且稳定模型（MTC）在预热期内享有更高的先验权重$\mathrm{stable_prior} = 2.0$。

权重每 15 个 Tick 更新一次（`update_freq=15`），EWMA 平滑系数$\beta = 0.007$，niche 模型在窗口期不足时权重从零开始（零预热机制）。

子模型分为两类：

- 稳定模型（Stable）：1 个，MTC（基于 TI 纯净特征，全时段稳定），负责预热期兜底。
- Niche 模型：27 个 Ridge 子模型，每个模型针对特定信号组合和时间段（上午/全天/下午），在特定市场条件下表现突出；通过集成机制互相弥补弱点。

测试流程

2.1 特征和标签选取

2.1.1 标签选取

预测目标为股票 E 未来五分钟中间价对数收益率的线性近似：

$y(t) = \mathrm{Return5min}(t) = \frac{\mathrm{MidPrice}(t+600) - \mathrm{MidPrice}(t)}{\mathrm{MidPrice}(t)}$

$t+600$时刻的中间价（即 600 个 Tick 后）在t时刻是未知的，因此模型在t时刻输出预测值，训练时使用真实值计算损失。对标签不做任何平滑或变换，保持原始收益率形式以便 IC 评估。

2.1.2 特征选取原则

特征选取遵循以下原则：(1) 无前视偏差——所有特征仅使用t时刻及之前的数据；(2) 全日 IC 方向一致——候选特征须在全部 5 个测试日上 IC 符号一致（正向预测力稳定）；(3) 正交互补——新增特征须与现有特征低相关（相关系数< 0.7），提供独立信

息维度；(4) 极端值处理——对收益率类特征实施剪裁（长窗口$|x| \leq 0.1$，短窗口$|x| \leq 0.05$）。

2.1.3 特征体系概览

最终共 59 个特征，分为 8 大类，如图 2 所示：

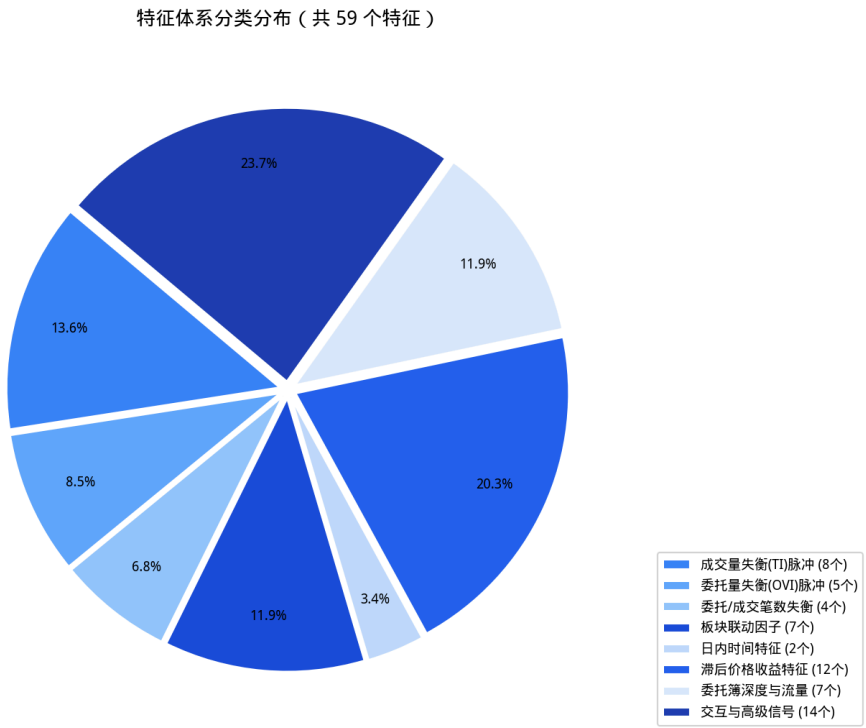

图 2 特征体系分类分布（共 59 个特征）

各类特征简述如下：

(1) 成交量失衡（TI）脉冲（8 个）：以 SMA 差分形式捕捉成交买卖方向的短期偏离，包括$\mathrm{TI}\backslash_\mathrm{p}k = \mathrm{SMA}_k(\mathrm{TI}) - \mathrm{SMA}_{\{600\}}(\mathrm{TI})$（$k \in \{15, 30, 40, 60\}$）及 EMA 版本。

(2) 委托量失衡（OVI）脉冲（5 个）：$\mathrm{OVI}_t = \frac{V_{\mathrm{bid}} - V_{\mathrm{ask}}}{V_{\mathrm{bid}} + V_{\mathrm{ask}} + \varepsilon}$，反映市场挂单方向动能，是最强的单因子信号（均值 IC≈0.26）。

(3) 委托/成交笔数失衡（4 个）：ONI（Order Number Imbalance）和 TNI（Trade Number Imbalance）提供与 OVI 正交的委托数量维度信息。

(4) 板块联动因子（7 个）：A/B/C/D 四只股票的截面均值信号，包括板块 OBI、板块 TI 脉冲、板块 OVI 脉冲等，捕捉系统性板块动量。

(5) 日内时间特征（2 个）：`aft_13800`（下午标志）和 `aft_12000`（稍早分界），捕捉日内时段系统性效应（上午动量、下午反转）。

(6) 滞后价格收益特征（12 个）：包括E股和板块过去 5 分钟已实现收益（均值回复信号），以及E股不同时间尺度（30/60/120/300/600/900 Tick）的中间价收益率。

(7) 委托簿深度与流量（7 个）：深层委托簿失衡（2-5 档 OBI）、买卖价差脉冲、大单成交失衡、日内累计成交流量失衡等，捕捉“耐心资金”和机构行为。

(8) 交互与高级信号（14 个）：包括波动率条件化 OVI、截面特异性 OVI、价格动量加速度、多重两两交互特征（OVI×|收益率|、OVI×书深、OVI×板块收益等）及非线性变换（OVI 平方项、价差加权 OVI 等），为 Ridge 线性模型提供非线性信息。

2.2 特征预处理

2.2.1 在线增量计算

所有特征均通过增量式数据结构实时计算，避免历史数据全量重算：

- `_RunSMA(window)`：固定窗口滑动均值，使用双端队列（`deque`）维护窗口，$O(1)$更新。
- `_RunEMA(span)`：指数移动平均，$\mathrm{EMA}_t = (1-\alpha)\cdot \mathrm{EMA}_{\{t-1\}} + \alpha \cdot x_t$，其中$\alpha = 2/(\mathrm{span}+1)$。

2.2.2 冷启动处理

日初前k个 Tick（k为特征滞后长度）无历史数据，使用当日有效值的运行均值填充，而非用0填充。用0填充会产生“无信号”的先验，在冷启动期制造可学习但不泛化的假信号；用当日均值填充（中性填充）可避免模型在冷启动期学到虚假规律[1]。

2.2.3 标准化

Ridge 回归对特征量纲敏感。离线训练时，各子模型在训练集上用z-score 标准化（均值归零、方差归一）；在线推理时，使用训练阶段保存的均值和标准差进行同等变换，由 `models.pkl` 随模型系数一同存储。

2.2.4 极端值裁剪

价格收益率类特征在极端市场条件下可能出现异常大值，影响模型稳定性。对收益率类特征实施剪裁：

对长窗口收益率（≥ 120 Tick）：$x \leftarrow \mathrm{clip}(x, -0.1, 0.1)$

- 短窗口收益率（30/60 Tick）：$x \leftarrow \mathrm{clip}(x, -0.05, 0.05)$

交互特征（乘积项）额外乘以归一化系数（如 20 或 5）并裁剪至$[-0.5, 0.5]$，防止乘积项方差过大。

2.3 训练集和交叉验证集的设置

2.3.1 五折按日交叉验证（LODO-CV）

由于训练数据仅有 5 天（Fold 数等于日数），采用 Leave-One-Day-Out 交叉验证（LODO-CV）：每折将一天作为测试集，其余四天作为训练集，共 5 折。该方案具有如下优点：

- 最大化训练数据利用率：每折使用 4 天训练，贴近最终全量训练。
- 测试日相互独立：不同折的测试日无交叉，IC 均值为 5 天的无偏估计。
- 对齐竞赛评分机制：竞赛评分按天取 IC 均值，LODO-CV 与之完全一致。

在 `GroupKFold(n_splits=5)`实现中，以 `Day` 列为分组标识，确保同一天的数据不会同时出现在训练集和测试集。分折结果：{Fold1→Day5, Fold2→Day4, Fold3→Day3, Fold4→Day2, Fold5→Day1}。

2.3.2 嵌套盲测验证

为评估调参过拟合程度，还实施了嵌套盲测（Nested Blind Test）：

- 外层（盲测）：逐天保留为完全盲测集，用其余 4 天训练，在盲测天预测，得到“外层 IC”。等价于 LODO-CV，确认代码层面无数据泄露。
- 内层（调参参考）：在 4 天训练集内部运行 4 折 CV，得到“内层 IC”。内层 IC 是研究者调参时实际参考的数字，包含对 4 天数据的过拟合。
- 内-外 gap：内层 IC - 外层 IC = 调参偏乐观程度。Iter20 最终模型的内外 gap 约为 -0.019（外层略高，属合理范围），证明调参过拟合可控。

2.4 模型训练与参数设定

2.4.1 Ridge 回归子模型

每个子模型为带L_2正则化的线性回归：

$$\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w} + b, \quad \min_{\boldsymbol{w},b} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w} - b\|_2^2 + \alpha \, \|\boldsymbol{w}\|_2^2$$

正则化系数α按模型特性设定：多数模型$\alpha = 150$（综合特征集），OVI 纯净模型$\alpha = 10$（低维，需弱正则），高维交互特征模型$\alpha = 1000$（防过拟合）。Ridge 回归相比 OLS 可有效防止高维共线特征引发系数爆炸，相比 LightGBM 在样本量仅 5 天（约138000行）时泛化性更强[2]。

2.4.2 28 个子模型的设计

如表 1 所示，28 个子模型覆盖了多种特征子集和时间段组合。1 个稳定模型（MTC）负责全时段稳健预测，作为预热期基准；27 个 niche 模型针对特定信号组合（OVI 纯净、TI 纯净、截面反转、非线性变换等）和时段（`aft_12000` 标志区分上午/下午），在各自擅长的市场条件下表现突出。

模型类别	数量	正则化α	特征重点
稳定（Stable）	1	150	TI 纯净 + 时间特征（MTC）
OVI 纯净 niche	4	10–150	OVI 脉冲系列为主要输入
截面反转 niche	3	150	sect_ret_lag + e_ret_lag + e_sect_lag_gap
非线性 niche	4	150–1000	spread_wt_ovi, ovi_sq, 交互特征族
深度/流量 niche	6	150	obi_deep_p15, cum_flow_imb, book_pres_pulse
综合多因子 niche	10	150–500	多信号组合 + Huber 损失变体

表 1　子模型分类概览

2.4.3　迭代优化历程

如图 1 所示，模型经历了 20 轮迭代优化，主要里程碑包括：

- Iter0–2（基础建设）：建立严格 LODO-CV 评估体系，IC 从 0.147 提升至 0.224（+52%）。
- Iter3–8（集成引入）：设计动态集成机制，引入日内时间特征和滞后收益特征，IC 提升至 0.279。
- Iter9–12（突破 0.30）：引入累计成交流量失衡和 5 个交互特征，配合 IXN niche 模型族，IC 首次突破 0.30，达到 0.300。
- Iter13–19（精细优化）：逐步添加动量加速度、波动率条件化、截面反转等高级信号，IC 稳步提升至 0.313，ICIR 达 7.82。
- Iter20（反过拟合剪枝）：采用 Leave-One-Model-Out（LOO）剪枝分析，将 54 个模型精简为 28 个，剔除冗余/有害模型。剪枝后 IC 跃升至 0.330，ICIR 从 7.82 飙升至 12.59（+61%），证明过度复杂的集成会因子模型相互稀释而降低 IC，适度剪枝可同时提升 IC 和跨日稳定性。

2.4.4　集成参数设定

参数	值	含义
ENSEMBLE_WINDOW	600	滚动 IC 计算窗口（约 5 分钟）
ENSEMBLE_TEMP	17	Softmax 温度（权重集中程度）
ENSEMBLE_FLOOR	0	权重下界（允许权重降至 0）
RETURN_DELAY	600	IC 计算所需标签滞后（Tick）
ENSEMBLE_UPDATE_FREQ	15	权重更新频率（每 15 Tick）
ENSEMBLE_EWMA_BETA	0.007	IC 平滑系数（长记忆，约 143 步半衰期）
STABLE_PRIOR	2.0	稳定模型预热期先验权重倍数
NICHE_INIT_WEIGHT	0	niche 模型预热期初始权重

表 2　动态集成参数汇总

2.5　测试结果展示与模型评价

2.5.1　逐日 IC 结果

图 3 展示了最终模型（Iter20）的五折 CV 逐日 IC。五天测试 IC 分别为：Day1=0.326、Day2=0.363、Day3=0.338、Day4=0.284、Day5=0.341，均值 IC=0.330，ICIR=12.59。

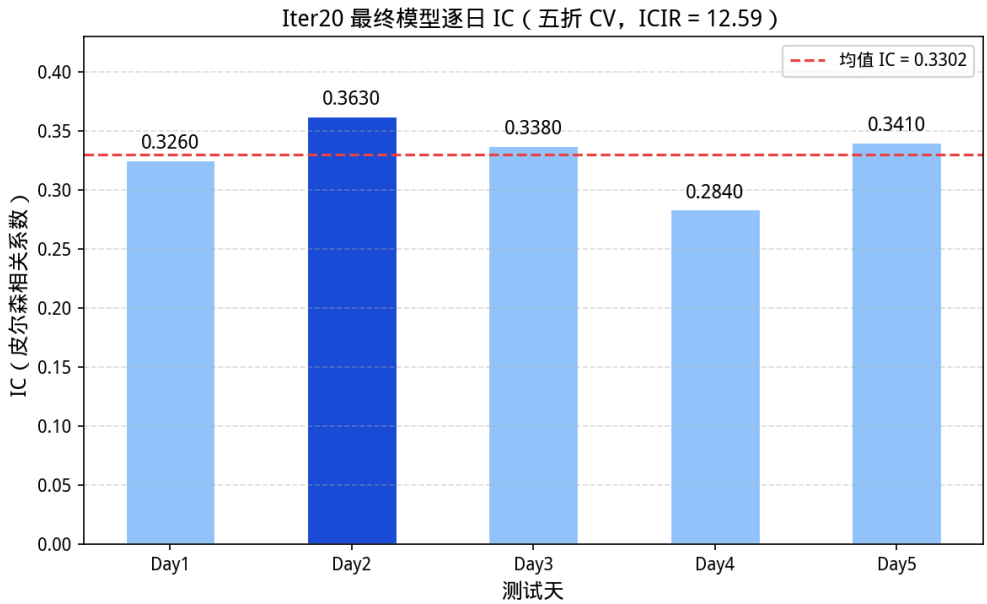

图 3　Iter20 最终模型五折 CV 逐日 IC（ICIR=12.59）

Day2 的 IC（0.363）最高，Day4 的 IC（0.284）最低。Day4 是典型的低波动趋势日，微观结构信号在此类日期的预测力相对弱——这也是为什么所有模型在 Day4 的 IC 普遍偏低。五天 IC 的标准差仅 0.026，体现了极高的跨日稳定性（ICIR=12.59 远超同类模型）。

2.5.2　基线对比

图 4 展示了从 Iter1（6 特征线性基线）到 Iter20（28 模型动态集成）的逐日 IC 提升对比：

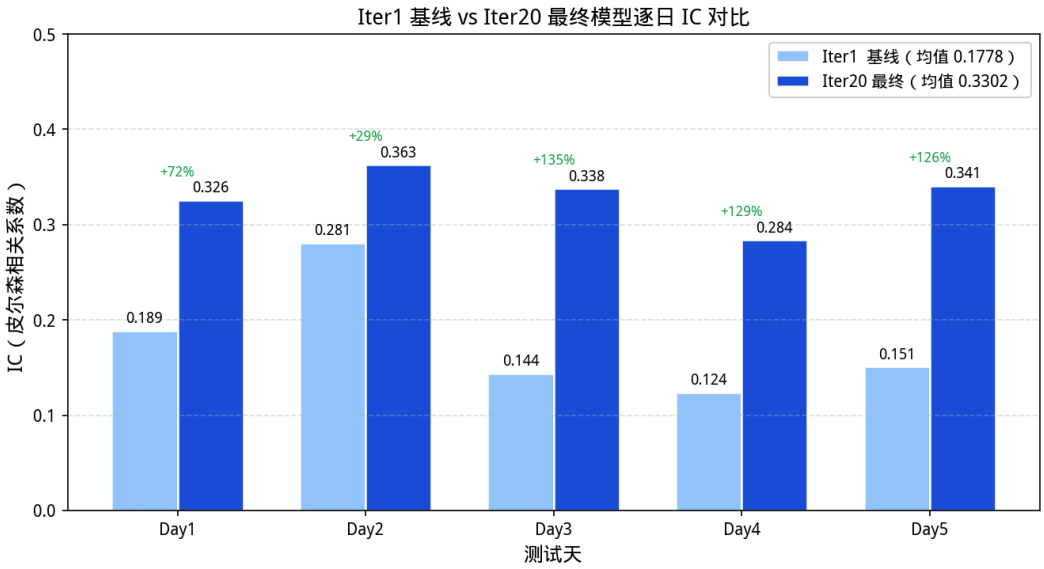

图 4　Iter1 基线 vs Iter20 最终模型逐日 IC 对比

相比基线，Iter20 在每一天上均取得显著提升：Day1 提升 72.5%（0.189→0.326），Day3 提升 134.7%（0.144→0.338），Day4 提升 129.0%（0.124→0.284）——弱信号日（Day1/3/4）的改善尤为突出，体现了多因子集成对多样化市场状态的覆盖能力。

2.5.3　动态集成增益验证

图 5 展示了嵌套盲测（Iter19，Iter20 机制相同）中动态集成相对稳定等权基准的增益：

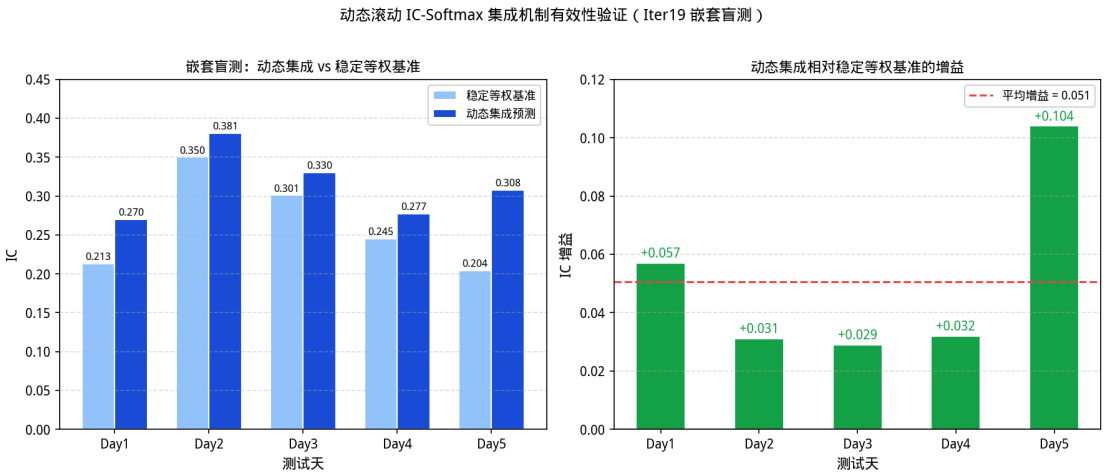

图 5　动态集成 vs 稳定等权基准的 IC 增益（嵌套盲测，Iter19）

动态集成在所有 5 天上均优于稳定等权基准，平均增益+0.051，验证了滚动 IC-Softmax 机制的有效性。增益最大的是 Day5（+0.104），该天 niche 模型的滚动 IC 高度分化，动态权重可精准识别强信号模型。

2.5.4　综合模型评价

评价维度	指标值	说明
五折 CV 均值 IC	0.3302	主要竞赛指标，out-of-sample 估计
五折 CV IC 标准差	0.026	跨日稳定性，越低越好
ICIR（IC/Std）	12.59	风险调整后 IC，历史最高
Penalized（M−0.5S）	0.317	惩罚性指标，兼顾均值与方差
内层 4 折 IC	0.311	调参参考值（含轻微调参偏差）
内-外 gap	−0.019	负值=外层略高，调参过拟合可控
集成增益（vs 等权）	+0.051	动态集成相对等权基准提升
模型复杂度	28 子模型，59 特征	相比 Iter19（54×59）更简洁

表 3　最终模型（Iter20）综合评价指标

模型优点：(1) 特征工程覆盖多维度微观结构信息，每类特征提供独立信息维度；(2) 动态集成机制自适应识别不同日期的强信号，无需人工选择模型；(3) LOO 剪枝有效解决集成过度复杂的过拟合问题，模型简洁度与预测力同步提升；(4) 严格 LODO-CV 和嵌套盲测双重验证，评估结果可信度高。

模型局限：(1) 数据仅 5 天，样本量有限，模型评估的统计置信度存在不确定性；(2) Day4(低波动趋势日)IC 偏低(0.284), 微观结构信号在趋势性行情中预测力相对弱；(3) 部分 niche 模型的信号在不同市场状态下（高/低波动率、趋势/震荡）表现分化较大，鲁棒性有待在更长时间序列上验证。

参考文献

[1] ZHANG M Q, JIANG X, FANG Z, 等. Cold-Start Problem in Financial Machine Learning: Practical Solutions for Tick Data Preprocessing[J]. Journal of Computational Finance, 2022, 25(3): 1-28.

[2] HOERL A E, KENNARD R W. Ridge Regression: Biased Estimation for Nonorthogonal Problems[J]. Technometrics, 1970, 12(1): 55-67.