

基于板块效应构建的多因子动态集成股票收益率预测模型

作者

李智 复旦大学 相辉学堂

徐智培 复旦大学 生命科学学院

欧阳子乐 复旦大学 计算与智能创新学院

摘要

针对股票 E 的未来五分钟收益率 (Return5min) 预测问题, 我们基于市场微观结构理论构建了一个结合板块联动信息的多因子动态集成模型。研究使用同一板块五只股票 (A/B/C/D/E) 连续 5 个交易日的 tick 级数据, 实现在线逐 tick 输出对股票 E 的未来 5 分钟收益率的预测。

在特征工程方面, 我们从原始数据中提取了 59 个多维度因子, 涵盖订单流失衡脉冲、深层委托簿压力、板块均值信号特征等多个维度。在建模方面, 我们训练了 28 个岭回归子模型 (1 个稳定模型与 27 个特化模型), 使用基于 EWMA 平滑滚动 IC 的 Softmax 动态集成算法, 实现在线自适应权重分配。

我们采取按日五折交叉验证的评估方法, 以预测值与真实收益率的五日平均 IC 与 ICIR 为主要评估标准, 最终模型五折均值 $IC=0.3302$, $ICIR=12.59$, 具备较强的预测能力与较高的跨日稳定性。本模型的高频预测能力及建模过程所用的方法在高频量化交易的实际任务中具有潜在应用价值。

关键词

股票收益率预测; 市场微观结构理论; 岭回归; 多模型动态集成; EWMA 平滑滚动 IC; Softmax 加权; 按日交叉验证; ICIR

模型介绍

1.1 问题描述

原始数据：五只股票（A/B/C/D/E）各提供 5 天历史数据，每天 27601 行 tick 快照（1tick=500ms），每只股票 33 个原始字段，包含快照类、委托类、成交类三种类型。

预测目标：股票 E 的未来五分钟中间价收益率

$$\text{Return5min}(t) = \frac{\text{MidPrice}(t + 600) - \text{MidPrice}(t)}{\text{MidPrice}(t)}$$

其中 $\text{MidPrice}(t) = \frac{\text{AskPrice1}(t) + \text{BidPrice1}(t)}{2}$

评价指标：股票 E 的未来 5 分钟预测收益率，与真实收益率的 N 日平均 IC 值。

1.2 模型架构

本模型的整体架构分为特征工程、离线训练和在线推理三个阶段。

特征工程阶段：以市场微观结构理论为基础，提出了多个特征并进行筛选，最终提取了 59 个多维度因子，涵盖成交量失衡脉冲、委托量失衡脉冲、深层委托簿压力、板块均值信号特征等，将处理后的数据统一保存为 `train.csv`。

离线训练阶段：以 `train.csv` 为训练数据，采取按日五折交叉验证的评估方式，以五日平均 IC 与 ICIR（信息比率，IC 均值与 IC 标准差的比值）为主要标准进行模型迭代，最终训练了 28 个岭回归子模型，模型参数保存至 `models.pkl`。

在线推理阶段：在线复现特征工程的计算，调用保存好的模型，并基于 EWMA 平滑滚动 IC 动态评估各个模型在当日历史的预测效果，以此进行多模型 Softmax 动态集成，加权后得到最终预测结果。

本模型以市场微观结构理论为严格的经济学基础构建特征工程体系，采用岭回归进行模型训练以应对高维多重共线性等问题，并采取了较为创新的稳健模型与特化模型相结合的动态集成策略。下面将详细阐述每个环节的设计思路与理论依据。

1.3 主要特征的数学原理与理论依据

本模型的特征工程部分以市场微观结构理论^[1,2]为主要理论依据。以下阐述几类主要特征的数学定义与经济学含义。

1.3.1 订单流失衡类特征

我们提取的订单流特征主要包括成交流与委托流两大类。

- **成交流：**令 tick 内主动买/卖成交量为 V_t^{buy} , V_t^{sell} ，定义成交量失衡（TI）为

$$TI_t = \frac{V_t^{\text{buy}} - V_t^{\text{sell}}}{V_t^{\text{buy}} + V_t^{\text{sell}} + \varepsilon}.$$

- **委托流：**令 tick 内新增买/卖委托量为 O_t^{buy} , O_t^{sell} , 定义委托量失衡 (OVI) 为

$$OVI_t = \frac{O_t^{\text{buy}} - O_t^{\text{sell}}}{O_t^{\text{buy}} + O_t^{\text{sell}} + \varepsilon}.$$

其中 ε 为小常数, 用于防止分母为零并增强数值稳定性。同理可定义成交笔数失衡 (TNI) 与委托笔数失衡 (ONI)。

微观结构理论认为, 买卖方向的持续不平衡反映了市场供需倾向与信息优势资金的交易压力, 因此往往领先于短期价格变化方向。这为我们选择 TI 与 OVI 作为核心特征提供了理论支持。

为强调近期订单流冲击相对长期基线的偏离, 进一步定义滑动均值与脉冲特征:

$$\bar{x}_{k(t)} = \left(\frac{1}{k}\right) \sum_{i=0}^{k-1} x_{t-i},$$

$$x_{p,k}(t) = \bar{x}_{k(t)} - \bar{x}_{600}(t).$$

脉冲变换提取了短期 (如 15/30/60 tick) 相对于较长期 (600 tick) 的偏离, 捕捉了订单流的突发变化, 这些突变往往是价格变动的先行指标, 因而对未来 5 分钟收益具有预测价值。

1.3.2 订单簿深度、价差与流动性状态特征

仅有订单流方向并不足以决定价格变化幅度。微观结构理论强调, 订单流对价格的冲击强弱依赖于流动性供给与信息不对称状态。因此, 我们引入了一系列刻画流动性状态的特征。

- **相对价差与价差脉冲：**令买卖一价分别为 $BidPrice_{t,1}$ 与 $AskPrice_{t,1}$, 中间价为

$$MidPrice_t = \frac{BidPrice_{t,1} + AskPrice_{t,1}}{2},$$

定义相对价差

$$spread_t = \frac{AskPrice_{t,1} - BidPrice_{t,1}}{MidPrice_t + \varepsilon}.$$

为刻画流动性成本的短期跳变, 进一步构造价差脉冲:

$$spread_p(t) = spread_t - \overline{spread}_{600}(t).$$

经济含义：价差扩大通常对应更高的逆向选择风险与更昂贵的即时成交成本, 因此在价差显著上升时, 订单流信号的边际影响可能被放大或更容易转为均值回复。

- 深层委托簿不平衡（2 - 5 档）：设第 l 档买/卖挂单量为 $\text{BidVol}_{t,l}, \text{AskVol}_{t,l}$ ，定义深层不平衡：

$$\text{OBI}_t^{\text{deep}} = \frac{\sum_{l=2}^5 \text{BidVol}_{t,l} - \sum_{l=2}^5 \text{AskVol}_{t,l}}{\sum_{l=2}^5 \text{BidVol}_{t,l} + \sum_{l=2}^5 \text{AskVol}_{t,l} + \varepsilon}.$$

并进一步构造其脉冲形式：

$$\text{OBI}_p^{\text{deep}}(t) = \overline{\text{OBI}^{\text{deep}}}_{15}(t) - \overline{\text{OBI}^{\text{deep}}}_{600}(t).$$

经济含义：深层挂单的变化速度慢于表层队列竞争，因此深层不平衡更能反映结构性供需倾向；当深层买盘明显占优时，短期回撤更可能得到承接，反之亦然。

- 大单成交方向：令主动买/卖成交金额为 $\text{Amt}_t^{\text{buy}}, \text{Amt}_t^{\text{sell}}$ ，对应成交笔数为 $N_t^{\text{buy}}, N_t^{\text{sell}}$ ，定义单笔平均成交额：

$$\text{AvgAmt}_t^{\text{buy}} = \frac{\text{Amt}_t^{\text{buy}}}{\max(N_t^{\text{buy}}, 1)},$$

$$\text{AvgAmt}_t^{\text{sell}} = \frac{\text{Amt}_t^{\text{sell}}}{\max(N_t^{\text{sell}}, 1)}.$$

再以短窗与长窗均值比值刻画大单强度的相对变化，并用买卖差构造方向性指标。

经济含义：大额交易更可能对应机构执行或信息型交易，其方向性往往更具持续性；因此该类特征用于在成交层面强化“信息优势资金”的识别。

- 日内累计成交净流：令日内累计主动买/卖成交量为

$$\text{CumBuy}_t = \sum_{s=0}^t V_s^{\text{buy}},$$

$$\text{CumSell}_t = \sum_{s=0}^t V_s^{\text{sell}}.$$

定义累计净流失衡

$$\text{CumFlowImb}_t = \frac{\text{CumBuy}_t - \text{CumSell}_t}{\text{CumBuy}_t + \text{CumSell}_t + \varepsilon}.$$

并做去基线处理：

$$\text{CumFlowImb}_p(t) = \text{CumFlowImb}_t - \overline{\text{CumFlowImb}}_{600}(t).$$

经济含义：累计净流刻画“到当前为止资金流偏向哪一侧”的慢变量，反映库存压力与日内趋势性资金的累积效应；其去趋势项用于突出当下相对日内平均的加速与转折。

1.3.3 板块联动与截面偏离特征

个股价格不仅受自身订单流影响，也受板块共同因子驱动。板块内多只股票共享宏观与行业信息冲击，并承受共同资金流的同步影响。为此，我们使用板块内 A/B/C/D 四只股票构造板块截面均值信号，以增强信噪比并刻画系统性联动。

设板块集合为 $\mathcal{S} = \{A, B, C, D\}$ 。对任意信号 $X_{s,t}$ （如 OVI、TI 等），定义板块均值：

$$\text{Sect}X_t = \left(\frac{1}{|\mathcal{S}|} \right) \sum_{s \in \mathcal{S}} X_{s,t}.$$

并构造其脉冲形式：

$$\text{Sect}X_{p,k}(t) = \overline{\text{Sect}X}_{k(t)} - \overline{\text{Sect}X}_{600}(t).$$

为刻画个股相对板块的特异性偏离，进一步定义相对偏离项：

$$\text{Rel}X_{E,t} = X_{E,t} - \text{Sect}X_t.$$

经济含义： $\text{Sect}X_t$ 代表共同冲击，而 $\text{Rel}X_{E,t}$ 则更接近个股特异信息。当个股委托压力显著强于板块均值时，往往对应定向资金或个股信息优势；反之亦然。

1.3.4 日内时段特征

高频数据具有显著日内时段差异：成交强度、价差与波动率随交易日内系统性变化，导致同一信号在不同时段的边际贡献不同。为刻画这一非平稳性，我们引入日内时段指示二值变量 $\text{aft}_{12000}(t)$ 与 $\text{aft}_{13800}(t)$ 。上述变量为模型提供可解释的“日内状态条件”，从而允许订单流与流动性信号在不同时段呈现不同的有效性。

1.3.5 条件化与交互特征

由于岭回归为线性模型，仅输入基础特征难以表达“某信号在某种状态下更有效”的条件关系。为此，我们构造条件化与交互特征，使模型在保持可解释性与在线可计算性的前提下，获得有限的非线性表达能力。

- **交互项（乘积项）：** 给定两个特征 $x_{1,t}$ 与 $x_{2,t}$ ，交互特征定义为

$$z_t = x_{1,t} * x_{2,t}.$$

它允许模型学习“边际作用随状态变化”的形式。

- **波动率条件化委托压力：** 以短期与长期波动率之比作为状态量，构造

$$\text{vol_ratio}_t = \frac{\text{sigma}_t^{\text{short}}}{\text{sigma}_t^{\text{long}} + \varepsilon},$$

$$\text{vol_cond_OVI}_t = \text{OVI}_{p,15}(t) * \text{vol_ratio}_t.$$

高波动往往对应信息到达率更高或流动性更脆弱，订单流对价格的解释力可能增强；低波动则相反。

- **截面剥离与反转类高级信号**：例如利用“个股与板块滞后收益差”构造截面反转信号

$$e_{\text{sect_lag_gap}}(t) = \text{sect_ret_lag}(t) - e_{\text{ret_lag}}(t).$$

当该值为正，表示个股过去 5 分钟跑输板块，短期可能存在向板块均值回归的压力；反之亦然。

1.4 岭回归模型的数学原理与选择依据

1.4.1 数学原理

岭回归通过在线性回归的损失函数中添加一个 L_2 正则化项来限制模型的复杂度，从而避免模型过度拟合训练数据^[3]。其优化目标为：

$$\min_{\mathbf{w}, b} \|\mathbf{y} - \mathbf{X}\mathbf{w} - b\|_2^2 + \alpha \|\mathbf{w}\|_2^2$$

其中 $\mathbf{X} \in \mathbb{R}^{n \times p}$ 为特征矩阵， $\mathbf{y} \in \mathbb{R}^n$ 为标签向量， $\mathbf{w} \in \mathbb{R}^p$ 为特征权重， $\alpha > 0$ 为正则化强度超参数。

L_2 正则化项通过对权重的平方和进行惩罚，让模型更倾向于减小权重的值，这可以防止模型过于依赖某些特征，从而更好地泛化到新数据。

此外， L_2 正则化虽然鼓励权重向零收敛，但不会像 L_1 正则化那样将权重变成零。因此， L_2 正则化通常只会导致较小但非零的权重值，从而使模型更加平滑和稳定。

1.4.2 岭回归在本任务中的优势

应对多重共线性。本模型的 59 个特征中，多类 OVI 脉冲彼此高度相关，TI 脉冲族同理。存在多重共线性时，最小二乘法的系数极不稳定，微小的数据扰动会导致系数剧烈震荡。而岭回归通过 L_2 正则化显式压缩相关特征的系数幅度，在保留全部特征信息的同时大幅降低估计方差，获得更稳定的泛化性能。

在小样本下的强泛化性。本模型的训练集规模约 110000 行（4 天训练集）、特征为 59 个，从数据量看并不小，但有效独立样本数远低于行数（相邻 tick 自相关性很强）。在有效样本受限的条件下，参数数量较少的正则化线性模型的泛化能力一般会优于高容量非线性模型（如 LightGBM）。

相比 Lasso 回归的连续可微优势。正如 1.4.1 节所述，Lasso 回归（ L_1 正则化）容易将部分相关特征的系数直接归零，可能丢失组合预测力。而岭回归对所有特征施加连续可微的二次惩罚，保留全部 59 个因子的联合贡献，能够兼顾完整性与稳定性。

1.5 动态集成机制的提出依据与数学推导

1.5.1 提出依据

我们观察到，单一模型在不同测试日或同日的不同时间段内的表现存在较大波动，且各个模型的优势区间存在显著差异，因此，不同模型在不同市场状态下能够具备互补的预测能力，尝试多模型集成有助于提升预测的稳定性。

另一方面，由于预测目标 Return5min 的计算公式已知，在线预测时可以实时计算出五分钟前的 Return5min 指标。我们决定利用这一点，在线评估各个模型在当日历史的预测效果，并据此动态调整各模型的权重。动态集成相比静态加权，能够根据市场状态的变化灵活调整权重，充分利用各模型的优势，从而提升整体预测性能。

动态集成虽然能够快速适应市场变化，但也存在过度反应短期噪声的风险。为了减少这类不稳定风险，我们使用 1 个稳定模型作为基准，在窗口积累不足时享有 2 倍先验权重，确保集成的稳健性；27 个特化模型则采用零预热机制，初始权重为 0，只有在积累足够 IC 历史后才参与集成，防止噪声 IC 污染早期权重估计。

1.5.2 数学推导

具体实现上，我们采取了基于 EWMA 平滑滚动 IC 的 Softmax 动态集成机制。

定义第 i 个子模型在滑动窗口 $[t-d-W, t-d)$ 内的滚动 IC 为：

$$IC_{i(t)} = \text{Pearson}(\{\hat{y}_{i(s)}\}_{s=t-d-W}^{t-d}, \{y(s)\}_{s=t-d-W}^{t-d})$$

其中 $W = 600$ tick (5 分钟窗口长度)， $d = 600$ tick (5 分钟时间滞后，确保标签 $y(t-d)$ 在 t 时刻已知)。

该值衡量了模型在近期窗口内的预测效果，但是受短期噪声的影响较大。因此，我们没有直接用 $IC_{i(t)}$ 来做权重，而是采取了指数量加权移动平均 (EWMA) 的方法，对历史数据赋予指数衰减的权重^[4]，从而得到更稳定的“模型得分” $\tilde{IC}_{i(t)}$ ：

$$\tilde{IC}_{i(t)} = (1 - \beta) \cdot \tilde{IC}_{i(t-\Delta)} + \beta \cdot IC_{i(t)}$$

其中 $\beta = 0.007$ (半衰期约 99 tick) 控制了平滑程度， $\Delta = 15$ 是权重更新频率 (每 15 tick 更新一次)。

最后，我们使用归一化指数函数 (Softmax 函数)^[5]，把 EWMA 平滑后的滚动 IC “得分” 变成非负且和为 1 的模型权重：

$$w_{i(t)} = \frac{\exp(\tilde{IC}_{i(t)} \cdot \tau)}{\sum_{j=1}^N \exp(\tilde{IC}_{j(t)} \cdot \tau)}$$

其中温度参数 $\tau = 17$ 控制了权重的集中程度。

最终输出的预测结果即各模型的预测值根据动态权重的加权平均：

$$\hat{g}(t) = \sum_{i=1}^N w_{i(t)} \cdot \hat{y}_{i(t)}$$

测试流程

2.1 特征和标签选取

2.1.1 标签选取

模型的预测目标为股票 E 的未来五分钟收益率。我们在训练时直接把它作为唯一标签，保持原始未处理的形式以便进行 IC 评估。

2.1.2 特征选取与筛选

我们基于 1.3 节所述的理论基础提出了多个方位的特征，并采用以下两个主要标准进行筛选，确保特征的有效性：


(1) **特征与标签的 IC**——计算候选特征与标签的五日 IC，以评估特征与标签的相关性。其中稳健模型的特征须在全部测试日上具备同号的高 IC，特化模型的部分特征则可以只在部分测试日上具备高 IC。我们通过这种筛选方式，来保证选取的特征对于标签预测具备足够的有效性，避免引入噪声特征。

(2) **正交互补**——新增特征与现有特征的 IC 不宜过高，以防止引入冗余特征。

2.1.3 特征体系概览

经过上述原则的筛选，我们最终构建了一个包含 59 个特征的多维度特征体系，涵盖了 8 大类，分别捕捉不同层次和维度的市场行为信号，为模型提供丰富且有效的预测信息。特征体系的概览如下：

特征体系分类分布（共 59 个特征）



其中的主要特征都在 1.3 节中进行了详细的数学定义与理论依据阐述，剩余大部分特征则是上述特征的各类变体，进一步丰富了模型的表达能力。

特别地，滞后价格收益特征（包含个股滞后收益和板块滞后收益），即已实现的 5 分钟收益滞后值（在线推理时严格可得），其在一定程度上刻画了近期是否经历了显著上涨/下跌冲击，从而为未来 5 分钟的延续或均值回复提供背景状态。

2.2 特征预处理

2.2.1 特征标准化

岭回归对特征量纲较为敏感，因此我们首先对特征在训练集上进行 Z-score 标准化 ($\hat{x} = (x - \mu)/\sigma$)；在线推理时使用训练阶段保存的 μ, σ 做相同变换，均值和标准差随模型系数存入 `models.pkl`。

2.2.2 极端值裁剪

为防止少量极端值影响模型系数，我们对部分特征实施了极端值裁剪：

- 长窗口收益率 (≥ 120 tick)：裁剪至 $[-0.1, 0.1]$
- 短窗口收益率 (30/60 tick)：裁剪至 $[-0.05, 0.05]$
- 交互特征（乘积项）：乘以归一化系数后裁剪至 $[-0.5, 0.5]$ ，防止乘积项方差过大。

2.2.3 冷启动处理

日初的一段时间缺少历史数据，需要对部分特征进行冷启动处理。对于历史窗口类特征，在样本数不足时使用已有样本的均值代替，而非用 0 填充，这可以避免模型学到虚假的冷启动规律；对于滞后标签类特征，在日初无法计算时直接用 0 填充。

2.3 训练集和交叉验证集的设置

2.3.1 按日五折交叉验证

我们在模型训练中采用按日五折交叉验证的方式，每折将一天作为测试集，其余四天作为训练集，重复五次。相比于固定训练集与验证集，该方法能够在避免数据泄漏的同时最大化利用训练数据，通过多次重复得到更加可信的结果，同时 ICIR 还能够有效评估模型的预测稳定性。

由于在线预测时的测试日互相独立，我们在训练时也没有刻意保持训练集的连续性，这样可以更好地模拟在线环境中的数据分布。此外，相比滚动时序交叉验证，按日交叉验证能够确保每折测试都具备足够的样本量，从而得到更有效的 IC 评估结果。

2.3.2 嵌套盲测验证

按日五折交叉验证的方式存在过拟合五日数据的风险。为定量评估调参过拟合程度^[2]，我们还实施了嵌套盲测：

- **内层（调参 IC）：** 在 4 天训练集内部运行四折交叉验证，并以平均 IC 作为调参依据，包含对 4 天数据的过拟合。
- **外层（盲测 IC）：** 在保留天进行盲测，模拟在线预测，评估模型在未知日的表现。
- **内外差值：** 重复上述过程五次后，对比内外层平均 IC，差值约为-0.019（外层略高），证明调参过拟合程度在可控的范围内。

2.4 模型训练和参数设定

2.4.1 岭回归模型

岭回归的数学原理与选择依据已在第 1.3 节详细阐述。实际模型训练中，我们也测试了 Lasso 回归、弹性网络、LightGBM 等模型类别，但效果都不如岭回归，因此我们最终选择了岭回归作为模型的基础算法。

2.4.2 子模型设计概览

我们最终训练了 28 个岭回归子模型，覆盖多种特征子集和时间段组合。1 个稳定模型负责全时段稳健预测，作为预热期基准；27 个特化模型则针对特定信号组合和时段，在各自擅长的市场条件下表现突出。子模型分类概览如下：

模型类别	数量	α	特征重点
稳定模型	1	200	成交方向脉冲 + 日内时段特征
委托方向特化	1	20	委托买卖压力脉冲 + 委托笔数失衡
深度/流量特化	3	20	日内累计成交净流 + 深层委托簿不平衡
截面板块特化	4	15 - 20	个股相对板块偏离 + 板块/个股滞后收益差
非线性/交互特化	6	15 - 20	价差条件化委托压力 + 委托压力非线性放大 + 多信号交互确认
综合多因子特化	13	15 - 20	订单流 + 价格动量/回归 + 流动性与状态条件化的组合

2.4.3 模型选取与调参方法

具体的子模型选取方式上，我们以单模型五折交叉验证的 IC 为主要评估标准，筛选出表现较好的模型类别和特征组合。此外，在部分测试日或特定时段内表现较好的模型也被保留，以利用其在特定市场状态下的优势。


为避免模型冗余与过拟合，我们采取了 Leave-One-Model-Out (LOO) 的反过拟合剪枝方法^[2]，逐一移除各个子模型并观察五折交叉验证平均 IC 的变化，以评估每个子

模型对集成性能的贡献。最终，我们从 54 个子模型中精简出 28 个，进一步提升了集成的 IC 和 ICIR。

调参方式上，我们在选取的子模型上进行了细致的网格搜索调参，以五折交叉验证的平均 IC 作为调参依据，调整的参数包括岭回归的正则化强度 α 、动态集成机制中的 EWMA 平滑参数 β 和 Softmax 温度参数 τ 等。

2.4.4 迭代历程总览

如下图所示，模型经历 20 轮迭代优化，IC 从基线的 0.147 稳步提升至 0.3302：




主要优化说明：

- Iter0 - 2 引入多个关键特征并选用岭回归训练模型，单模型 IC 从基线的 0.147 提升至 0.224。
- Iter3 - 4 引入多模型动态集成机制与日内时间特征，IC 提升至 0.279。
- Iter9 - 12 引入累计流量失衡和交互特征，IC 突破 0.30 的目标。
- Iter13 - 19 加入动量加速度、波动率条件化、截面异质 OVI 等高级信号，IC 稳步提升至 0.313，ICIR 达 7.82。
- Iter20 采用 L00 反过拟合剪枝，54 个模型精简为 28 个，IC 提升至 0.330，ICIR 从 7.82 跃升至 12.59 (+61%)，模型稳定性大幅提升。

2.5 测试结果展示和模型评价

2.5.1 逐日 IC 结果


下图展示了最终模型（Iter20）的五折交叉验证逐日 IC：



五日均值 IC 达到 0.3302, 标准差仅 0.026, ICIR=12.59, 体现了较强的预测能力与较高的跨日稳定性。

2.5.2 基线对比

下图展示了从 Iter1 (6 特征线性基线) 到 Iter20 (28 模型动态集成) 的逐日 IC 提升:




相比基线, Iter20 在每一天上均取得显著提升, 弱信号日 (Day1/3/4) 的改善尤为突出, 体现了多因子集成对多样化市场状态的覆盖能力。

2.5.3 动态集成增益验证

下图展示了嵌套盲测中动态集成相对稳定等权基准的增益:

动态滚动 IC-Softmax 集成机制有效性验证 (Iter19 嵌套盲测)



动态集成在 5 天上均优于等权基准，平均增益+0.051，验证了滚动 IC-Softmax 机制的有效性。增益最大的是 Day5 (+0.104)，该日特化模型的滚动 IC 高度分化，动态权重精准识别了强信号模型。

2.5.4 模型综合评价

评价维度	指标值	说明
五折 CV 均值 IC	0.3302	主要评估指标
五折 CV IC 标准差	0.026	体现跨日稳定性
ICIR (IC 均值/标准差)	12.59	综合评价模型预测能力与稳定性 ^[1]
内层 4 折 IC	0.311	调参参考值 (含轻微调参偏差)
内外差值	-0.019	外层略高，调参过拟合可控
集成增益	+0.051	动态集成相对等权基准提升
模型复杂度	28 子模型, 59 特征	相比 Iter19 (54×59) 更简洁

本模型基于市场微观结构理论构建多维度特征体系，结合岭回归的稳定性与动态集成的适应性，经过五折交叉验证与嵌套盲测验证等测试，被证实在股票 E 未来五分钟收益率预测任务中具备较强的综合预测能力。

实际应用中，本模型的较强预测能力使其在高频量化交易的实际任务中具备一定的应用前景。此外，建模过程中的特征构建思路、模型选择原则以及动态集成机制的设计方法也具有一定的通用性，可以为类似的高频预测任务提供有价值的参考。

参考文献

- [1] DeepSeek[EB/OL]. (2026). <https://chat.deepseek.com/>.
- [2] GitHub Copilot[EB/OL]. (2026). <https://github.com/copilot/>.
- [3] JAVA1234 官方. Scikit-learn Python 机器学习 视频教程[EB/OL]. (2026). <https://www.bilibili.com/video/BV11reUzEEPH>.
- [4] 指数加权移动平均_百度百科[EB/OL]. (2026). <https://baike.baidu.com/item/%E6%8C%87%E6%95%B0%E5%8A%A0%E6%9D%83%E7%A7%BB%E5%8A%A8%E5%B9%B3%E5%9D%87/24430551>.
- [5] 归一化指数函数_百度百科[EB/OL]. (2026). <https://baike.baidu.com/item/%E5%BD%92%E4%B8%80%E5%8C%96%E6%8C%87%E6%95%B0%E5%87%BD%E6%95%B0/24430551>.